电商数据分析

2020年6月11日

电商数据分析

列作为索引

```
[108]: import numpy as np import pandas as pd import matplotlib.pyplot as plt

[109]: # 加载数据, 加载之前先用文本编辑器看下数据的格式, 首行是什么, 分隔符是什么等 df = pd.read_csv('./order_info_2016.csv', index_col='id') # 使用文件内容的 id
```

[110]: df.head()

```
「110]:
            orderId
                      userId productId cityId
                                                 price payMoney
                                                                   channelId \
      id
      1
          232148841 2794924
                                   268 110001
                                                 35300
                                                           35300 9058255c90
          222298971 1664684
                                   801
                                        330001
                                                 51200
                                                           49900
                                                                 e0e6019897
          211494392 2669372
                                   934 220002
                                                 62100
                                                                 9058255c90
      3
                                                           62100
          334575272 1924727
                                   422 230001
                                                 50600
                                                           42000
                                                                 46d5cea30d
      5
          144825651 4148671
                                   473 130006 149100
                                                          142000 6ff1752b69
                              createTime
          deviceType
                                                      payTime
      id
      1
                   3 2016-01-01 12:53:02 2016-01-01 12:53:24
                   2 2016-01-01 21:42:51 2016-01-01 21:43:30
      2
                   3 2016-01-01 14:10:13 2016-01-01 14:11:18
      3
      4
                   2 2016-01-01 17:43:35 2016-01-01 17:43:53
                   2 2016-01-01 18:52:04 2016-01-01 18:52:47
```

[111]: df.info() # 查看数据的行列数量以及数据类型

<class 'pandas.core.frame.DataFrame'>

Int64Index: 104557 entries, 1 to 104557

Data columns (total 10 columns):

orderId 104557 non-null int64 userId 104557 non-null int64 104557 non-null int64 productId 104557 non-null int64 cityId 104557 non-null int64 price 104557 non-null int64 payMoney channelId 104549 non-null object deviceType 104557 non-null int64 createTime 104557 non-null object payTime 104557 non-null object

dtypes: int64(7), object(3)

memory usage: 8.8+ MB

[112]: df.count() # 查看各个列的非空数据量

[112]: orderId 104557 userId 104557 productId 104557 cityId 104557 price 104557 payMoney104557 channelId 104549 deviceType 104557 createTime 104557 payTime 104557

dtype: int64

[113]: df.describe()

[113]: orderId userId productId cityId price \ 1.045570e+05 1.045570e+05 104557.000000 104557.000000 1.045570e+05 count 2.993341e+08 3.270527e+06 154410.947225 9.167350e+04 mean 504.566275 std 5.149818e+07 4.138208e+07 288.130647 72197.163762 9.158836e+04 0.000000 30000.000000 6.000000e+02 min 1.035627e+08 2.930600e+04

```
25%
             2.633627e+08 2.179538e+06
                                            254.000000
                                                        100011.000000 3.790000e+04
      50%
             2.989828e+08
                           2.705995e+06
                                            507.000000
                                                        150001.000000
                                                                       5.920000e+04
      75%
             3.349972e+08
                           3.271237e+06
                                            758.000000
                                                        220002.000000
                                                                       1.080000e+05
             4.871430e+08 3.072939e+09
                                            1000.000000 380001.000000 2.295600e+06
      max
                 payMoney
                              deviceType
             1.045570e+05
                           104557.000000
       count
             8.686689e+04
                                2.385292
      mean
      std
             9.072028e+04
                                0.648472
            -1.000000e+03
                                1.000000
      min
      25%
             3.360000e+04
                                2.000000
       50%
             5.500000e+04
                                2.000000
      75%
             1.040000e+05
                                3.000000
             2.294200e+06
                                6.000000
      max
[114]: # 加载 device_type
       device_type = pd.read_csv('./device_type.txt')
[115]: device_type
[115]:
         id deviceType
       0
          1
                    PC
          2
               Android
       1
       2
          3
                iPhone
       3
          4
                   Wap
       4
          5
                 other
      0.0.1 开始进行数据清洗
[116]: # order_id
       # order_id 应该是唯一的,查看是否有重复值
       df.orderId.unique().size
[116]: 104530
```

0.0.2 order_id 列有重复值,处理完其它类型的问题后再删除

[117]: # userId # 对于订单数据,一个用户有可能有多个订单,重复值是合理的 df.userId.unique().size [117]: 102672 [118]: # productId # productId 最小值是 O, 查看值为 O 的记录数量 df.productId[(df.productId == 0)].size [118]: 177 [119]: # 删除异常值 df.drop(index=df[df.productId==0].index, inplace=True) [120]: # cityId # cityId 值都在正常范围,不需要处理,有重复值是正常的 df.cityId.unique().size [120]: 331 [121]: # price # price 没有空值, 且都大于 0, 单位是分, 把它变成元 df.price = df.price / 100 [122]: # payMoney # payMoney 有负值,下单不可能是负值,所以对于负值的记录要删除掉 # 查看负值的记录 df[df.payMoney < 0]</pre> [122]: channelId \ orderId userId productId cityId price payMoney id 25344 288096069 230014 2145955 511 111.0 -1000 df9f79c426 55044 296608442 4073997 120006 111.0 -1000 cbccc0808e 385 60019 2084.0 66897 316685479 1949907 554 -1000 9058255c90 72556 323229098 2894042 548 220008 114.0 -1000 41a4e91d29

40001

116.0

797

-990 ea5648bbe2

81494 311194385 3370399

87878 324068352 1873953 602 260003 292.0 -1000 9058255c90

	deviceType	createTime	payTime
id			
25344	2	2016-03-11 21:32:54	2016-03-11 21:33:10
55044	2	2016-05-24 08:52:04	2016-05-24 08:52:23
66897	3	2016-03-31 11:57:46	2016-03-31 11:57:46
72556	2	2016-08-09 14:24:13	2016-08-09 14:24:26
81494	1	2016-09-06 11:20:43	2016-09-06 11:21:31
87878	3	2016-10-05 10:47:05	2016-10-05 10:47:05

[123]: # 删除负值的记录

df.drop(index=df[df.payMoney < 0].index, inplace=True)</pre>

[124]: # 再看下, 已经没有了

df[df.payMoney < 0].index</pre>

[124]: Int64Index([], dtype='int64', name='id')

[125]: # 变成元

df.payMoney = df.payMoney / 100

[126]: # channelId

channelId 根据 info 的结果, 有些 null 的数据, 可能是客户端的 bug 等原因, 在下单的时候没有传 channelId 字段

数据量大的时候, 删掉少量的 null 记录不会影响统计结果

查看为 null 的数据

df[df.channelId.isnull()]

[126]:		orderId	userId	productId	cityId	price	payMoney	channelId	\
	id								
	19086	284008366	3309847	698	240001	2164.0	2040.0	NaN	
	38175	287706890	2799815	823	70001	760.0	749.0	NaN	
	48073	248057459	3970570	142	130001	474.0	400.0	NaN	
	75949	266847859	3761925	649	120006	257.0	257.0	NaN	
	100952	283627429	4156620	269	280001	484.0	410.0	NaN	
	100953	346836140	3751526	738	100013	105.0	80.0	NaN	
	100954	352853915	2229389	786	240001	474.0	440.0	NaN	

100955 379473081 4531810 18 180009 146.0 50.0 NaN deviceType createTime payTime id 2 2016-03-08 22:36:12 2016-03-08 22:36:50 19086 38175 3 2016-06-10 22:30:18 2016-06-10 22:30:47 48073 2 2016-03-30 12:59:03 2016-03-30 12:59:13 75949 2 2016-08-19 08:46:22 2016-08-19 08:46:39 100952 2 2016-12-13 13:24:37 2016-12-13 14:47:08 100953 1 2016-12-13 13:47:34 2016-12-13 13:47:44 100954 2 2016-12-13 16:54:09 2016-12-13 16:55:00 100955 3 2016-12-13 20:18:22 2016-12-13 20:18:34 [127]: # 删除 df.drop(index=df[df.channelId.isnull()].index, inplace=True) [128]: # 再查看 df[df.channelId.isnull()] [128]: Empty DataFrame Columns: [orderId, userId, productId, cityId, price, payMoney, channelId, deviceType, createTime, payTime] Index: [] [129]: # deviceType 的取值与 device_type.txt 文件对比后没有问题,不需要处理 [130]: # createTime 和 payTime 都没有 null, 不过是要统计 2016 年的数据, 把非 2016 年的删掉 # 先把 createTime 和 payTime 转换成 datetime 格式 df.createTime = pd.to_datetime(df.createTime) df.payTime = pd.to_datetime(df.payTime) df.dtypes [130]: orderId int64 userId int64 productId int64 int64 cityId float64 price

float64

payMoney

```
channelId
                             object
      deviceType
                             int64
                    datetime64[ns]
      createTime
      payTime
                     datetime64[ns]
      dtype: object
[131]: import datetime
      startTime = datetime.datetime(2016, 1, 1)
      endTime = datetime.datetime(2016, 12, 31, 23, 59, 59)
[132]: df[df.createTime < startTime]
[132]:
                          userId productId cityId price payMoney
                                                                       channelId \
               orderId
      id
      53
                        2497737
                                            180015 336.0
              263312190
                                       583
                                                               336.0 9058255c90
      18669
             188208169
                        3277974
                                        82
                                             60021 752.0
                                                               740.0 9058255c90
      36650
             254118088
                        1861372
                                         64
                                            210010 249.0
                                                               249.0 9058255c90
      71638
             203314910
                        3207233
                                            180011 662.0
                                                               580.0 41a4e91d29
                                       302
      88692 283989279
                        2830413
                                        290
                                            330005 467.0
                                                               460.0 df9f79c426
             deviceType
                                  createTime
                                                         payTime
      id
      53
                       3 2015-08-14 09:40:34 2016-01-01 14:47:14
                      3 2015-11-02 20:17:25 2016-01-19 20:06:35
      18669
      36650
                      2 2015-02-14 12:20:36 2016-02-28 13:38:41
                      1 2015-11-19 10:36:39 2016-08-07 12:24:35
      71638
      88692
                      2 2015-12-26 11:19:16 2016-10-01 07:42:43
```

0.0.3 有 16 年之前的数据, 需要删掉

```
[133]: df.drop(index=df[df.createTime < startTime].index, inplace=True)

[134]: df[df.createTime < startTime] # 再查看是否有 16 年之前的数据
```

Index: [] [135]: df.drop(index=df[df.createTime > df.payTime].index, inplace=True) # payTime 早 于 createTime 的也需要删掉 [136]: # 处理 16 年之后的数据 df[df.createTime > endTime] [136]: Empty DataFrame Columns: [orderId, userId, productId, cityId, price, payMoney, channelId, deviceType, createTime, payTime] Index: [] [137]: # 看下支付时间有没有 16 年以前的 df[df.payTime < startTime]</pre> [137]: Empty DataFrame Columns: [orderId, userId, productId, cityId, price, payMoney, channelId, deviceType, createTime, payTime] Index: [] [138]: # 把 orderId 重复的记录删掉 df.drop(index=df[df.orderId.duplicated()].index, inplace=True) [139]: df.describe() [139]: orderId userId productId cityId \ 1.043290e+05 1.043290e+05 104329.000000 104329.000000 count 2.993327e+08 3.271862e+06 505.441622 154432.178100 mean std 5.150568e+07 4.142725e+07 287.622456 72131.599487 1.035627e+08 2.930600e+04 30000.000000 1.000000 min 2.633440e+08 2.179758e+06 25% 255.000000 100011.000000 50% 2.989888e+08 2.706195e+06 508.000000 150001.000000 75% 3.350016e+08 3.271317e+06 759.000000 220002.000000 4.871430e+08 3.072939e+09 1000.000000 380001.000000 max

deviceType

payMoney

count 104329.000000 104329.000000 104329.000000

price

mean	917.113669	869.043120	2.385358
std	916.240224	907.576637	0.648439
min	6.000000	0.000000	1.000000
25%	379.000000	336.000000	2.000000
50%	593.000000	550.000000	2.000000
75%	1080.000000	1040.000000	3.000000
max	22956.000000	22942.000000	6.000000

0.1 数据清洗完毕,开始分析

0.1.1 先看下数据的总体情况:总订单数,总下单用户,总销售额,有流水的商品数

```
[140]: print(df.orderId.count())
    print(df.userId.unique().size)
    print(df.payMoney.sum())
    print(df.productId.unique().size)
```

102447 90666399.7

.

1000

0.1.2 按照商品的 productId, 看下商品销量的前十和后十个

```
[146]: productId_orderCount = df.groupby('productId').count()['orderId'].

→sort_values(ascending=False)

print(productId_orderCount.head(10)) # 商品销量的前十
```

productId

895 354

762 350

103 334

587 303

385 302

60 301

38 301


403 297

345 292823 288

Name: orderId, dtype: int64

[144]: productId_orderCount.head(10).plot(kind='bar')

[144]: <matplotlib.axes._subplots.AxesSubplot at 0x13e04608>




[147]: print(productId_orderCount.tail(10)) # 商品销量的后十

98616100013

Name: orderId, dtype: int64

[145]: productId_orderCount.tail(10).plot(kind='bar')

[145]: <matplotlib.axes._subplots.AxesSubplot at 0x1242aa48>



0.1.3 按照商品的 productId, 看下商品销售额的前十和后十个

```
[148]: productId_turnover = df.groupby('productId').sum()['payMoney'].

→sort_values(ascending=False)

print(productId_turnover.head(10)) # 商品销售额的前十
```

productId

385 427522.1

61 361572.0

103 344641.2


405 339525.0

```
720 322405.1
345 320162.2
698 318458.6
182 296600.0
383 280790.0
396 269556.0
```

Name: payMoney, dtype: float64

```
[149]: productId_turnover.head(10).plot(kind='bar')
```

[149]: <matplotlib.axes._subplots.AxesSubplot at 0x13bc5fc8>



[150]: print(productId_turnover.tail(10)) # 商品销售额的后十


```
productId
310 22879.0
847 22869.0
454 22535.0
817 22509.0
```

597 21847.0 408 18111.0 986 14784.0 964 14238.0 1000 12169.0 347 12070.0

Name: payMoney, dtype: float64

[151]: productId_turnover.tail(10).plot(kind='bar')

[151]: <matplotlib.axes._subplots.AxesSubplot at 0x123234c8>



0.1.4 看下销量和销售额最后 **100** 个的交集,如果销量和销售额都不行,这些商品需要看看是不是要优化或者下架

```
[152]: problem_productIds = productId_turnover.tail(100).index.
       →intersection(productId_orderCount.tail(100).index)
      problem_productIds
[152]: Int64Index([ 14, 807, 599, 676,
                                           7, 469,
                                                    577,
                                                          551,
                                                                318,
                                                                      220,
                                                                           528,
                  303,
                        314, 359, 629, 582,
                                               985,
                                                    218,
                                                          578,
                                                                227,
                                                                      277,
                                                                           145,
                  855, 586, 958, 91, 856, 948,
                                                    859.
                                                          874.
                                                                806.
                                                                     272.
                                                                          392,
                   27, 460, 436, 468,
                                         579, 868,
                                                    137,
                                                           16,
                                                                590,
                                                                      247, 569,
                  242,
                        104, 621, 478, 310, 847,
                                                    454,
                                                          817,
                                                                597,
                                                                      408,
                                                                           986,
                  964, 1000, 347],
                 dtype='int64', name='productId')
```

0.1.5 按照城市分类,看下商品销量的前十和后十的城市

```
cityId
110001
          5490
130001
          4100
60011
          3639
40001
          3291
220002
          3051
230001
          2951
240001
          2753
120001
          2435
220005
          2168
70001
          2075
Name: orderId, dtype: int64
cityId
280012
          1
280010
          1
280008
          1
```

```
70002
          1
240006
          1
90024
180023
          1
170031
          1
160005
380001
          1
```

Name: orderId, dtype: int64

0.1.6 按照城市分类,看下商品销售额的前十和后十的城市


```
[154]: cityId_payMoney = df.groupby('cityId').sum()['payMoney'].
       ⇔sort_values(ascending=False)
       print(cityId_payMoney.head(10))
       print(cityId_payMoney.tail(10))
      cityId
      110001
                6127732.8
                4406761.8
      220002
      130001
                3961264.7
      220005
                3374686.7
      60011
                2787478.1
      40001
                2531856.7
      120001
                2418538.8
      70001
                2192634.7
      230001
                2176484.0
      220001
                1983682.4
      Name: payMoney, dtype: float64
      cityId
      310005
                710.0
      90030
                700.0
      280010
                700.0
      380001
                667.0
      360016
                430.0
      280012
                420.0
      90012
                370.0
                177.0
      90029
```

```
70002 110.0
180023 30.1
```


Name: payMoney, dtype: float64

0.1.7 对于价格,看下所有商品价格的分布,这样可以知道什么价格的商品卖的最好

```
[155]: # price
       # 先按照 100 的区间取分桶
       bins = np.arange(0, 10000, 100)
       pd.cut(df.price, bins).value_counts()
[155]: (400, 500]
                      14791
       (300, 400]
                       10737
       (200, 300]
                        9966
       (500, 600]
                        9189
       (600, 700]
                        8777
       (8200, 8300]
                           0
       (9700, 9800]
                           0
       (7700, 7800]
                           0
       (7400, 7500]
                           0
       (9800, 9900]
                           0
       Name: price, Length: 99, dtype: int64
[157]: # 直方图
       # plt.figure(figsize=(16, 16))
       plt.hist(df['price'], bins)
       plt.show()
```



0.1.8 很多价格区间没有商品,如果有竞争对手的数据,可以看看是否需要补商品填充对应的价格区间



[160]: # channelId

渠道的分析类似于 productId, 可以给出成交量最多的渠道, 订单数最多的渠道等, 渠道很多时候是需要花钱买流量的,

所以还需要根据渠道的盈利情况和渠道成本进行综合比较,同时也可以渠道和商品等多个维度综合分析,看看不同的卖的最好的商品是否相同


0.1.9 按小时的下单量分布,可以按时间做推广,中午 **12**,**13**,**14** 点下单比较多,应该是午休的时候,然后是晚上 **20** 点左右,晚上 **20** 点左右几乎是所有互联网产品的一个高峰,下单高峰要注意网站的稳定性、可用性

```
[161]: # 下单时间分析

df['orderHour'] = df.createTime.dt.hour

df.groupby('orderHour').count()['orderId'].plot()
```

[161]: <matplotlib.axes._subplots.AxesSubplot at 0x15ae5c48>



0.1.10 按照星期来看,周五下单最多,其次是周六

```
[162]: df['orderWeek'] = df.createTime.dt.dayofweek
       df.groupby('orderWeek').count()['orderId']
[162]: orderWeek
       0
            12503
       1
            12484
       2
            12932
            13794
       3
       4
            16198
       5
            19496
            16922
       Name: orderId, dtype: int64
[163]: df.groupby('orderWeek').count()['orderId'].plot()
[163]: <matplotlib.axes._subplots.AxesSubplot at 0x15b41608>
```




```
[164]: # 下单后多久支付
       def get_seconds(x):
           return x.total_seconds()
       df['payDelta'] = (df['payTime'] - df['createTime']).apply(get_seconds)
[166]: bins = [0, 50, 100, 1000, 10000, 100000]
       pd.cut(df.payDelta, bins).value_counts()
[166]: (0, 50]
                          79229
       (100, 1000]
                          12899
       (50, 100]
                          10674
       (1000, 10000]
                            968
       (10000, 100000]
                            231
```

Name: payDelta, dtype: int64

0.1.11 绝大部分都在十几分钟之内支付完成,说明用户基本很少犹豫,购买的目的性很强

[167]: # 饼图看下 pd.cut(df.payDelta, bins).value_counts().plot(kind='pie', autopct='%d%%',□ →shadow=True, figsize=(6, 6))


[167]: <matplotlib.axes._subplots.AxesSubplot at 0x15a053c8>



0.1.12 每月的成交额,最大值出现在七月

```
[168]: # 月成交额
# 先把创建订单的时间设置为索引
df.set_index('createTime', inplace=True)
turnover = df.resample('M').sum()['payMoney']
turnover.plot()
```

[168]: <matplotlib.axes._subplots.AxesSubplot at 0x15910e08>



0.1.13 每月的下单总数,最大值出现在七月

```
[169]: order_count = df.resample('M').count()['orderId']
    order_count.plot()
```

[169]: <matplotlib.axes._subplots.AxesSubplot at 0x159f41c8>

